Omnix: Análisis de datos económicos impulsado por IA y RAG

Diógenes Lugo
Data Scientist · BI Consultant
Madrid, España
KeepCoding

16-04-2026

Abstracto

El crecimiento exponencial de la información en formato documental, especialmente en repositorios técnicos y académicos, plantea desafíos significativos para la recuperación eficiente de conocimiento relevante. Los métodos tradicionales de búsqueda basada en palabras clave presentan limitaciones en la comprensión semántica y en la capacidad de responder preguntas complejas de manera contextualizada.
Este trabajo aborda el desarrollo de un sistema basado en Retrieval-Augmented Generation (RAG), cuyo objetivo es permitir la consulta inteligente de colecciones de documentos en formato principalmente Markdown mediante el uso combinado de modelos de embeddings, almacenamiento vectorial y modelos de lenguaje. El sistema procesa los documentos mediante técnicas de segmentación y preprocesamiento, genera representaciones vectoriales de los fragmentos textuales y utiliza mecanismos de similitud semántica para recuperar la información más relevante en función de una consulta del usuario.
Posteriormente, un modelo generativo utiliza el contexto recuperado para construir respuestas coherentes y fundamentadas en los documentos fuente. Este enfoque permite reducir la dependencia de búsquedas exactas, mejorar la precisión en la recuperación de información y facilitar la interacción natural con grandes volúmenes de conocimiento no estructurado.
El resultado es una arquitectura modular que transforma colecciones documentales estáticas en sistemas dinámicos de consulta, aportando valor en escenarios donde el acceso rápido y contextualizado a la información es crítico.

Índice

1. Introducción **3**

2. Antecedentes y Motivación **4**

3. Metodología **5**

3.1. Ingesta y Preprocesamiento de Documentos 5

3.2. Generación de Embeddings 5

3.3. Vector Store y Recuperación de Información 6

3.4. Generación de Respuestas (LLM + Prompting) 7

3.5. API y despliegue del sistema 8

4. Experimentos y Evaluación **9**

4.1. Caso 1: Consulta fuera de dominio 9

4.2. Caso 2: Consulta dentro de dominio 10

5. Resultados **11**

6. Guía de Uso **12**

7. Conclusiones y Trabajo Futuro **14**

8. Referencias **15**

1 Introducción

En la actualidad, el volumen de información digital, especialmente en documentos extensos como artículos académicos e informes técnicos, crece de forma constante. Esto dificulta el acceso eficiente a información específica dentro de colecciones no estructuradas. Los métodos tradicionales basados en palabras clave resultan limitados al no capturar el contexto semántico, lo que puede generar respuestas incompletas o imprecisas.

Ante este escenario, surge la necesidad de sistemas capaces de comprender consultas en lenguaje natural y recuperar información de manera contextualizada. Este trabajo propone un sistema de Question Answering sobre documentos Markdown basado en la arquitectura Retrieval-Augmented Generation (RAG), que combina recuperación de información con modelos generativos de lenguaje.

El objetivo es *permitir consultas semánticas mediante la recuperación de fragmentos relevantes y la generación de respuestas fundamentadas*. Para ello, se integran técnicas de segmentación de texto, generación de embeddings, bases de datos vectoriales y modelos de lenguaje.

El problema se aborda como una tarea de recuperación y generación condicionada por contexto, donde la calidad de la respuesta depende de la relevancia de los fragmentos recuperados y su correcta interpretación. Así, el sistema transforma repositorios estáticos en herramientas dinámicas de consulta.

En la Figura 1 se presenta un diagrama de flujo que resume el funcionamiento general del sistema y la interacción entre sus componentes.

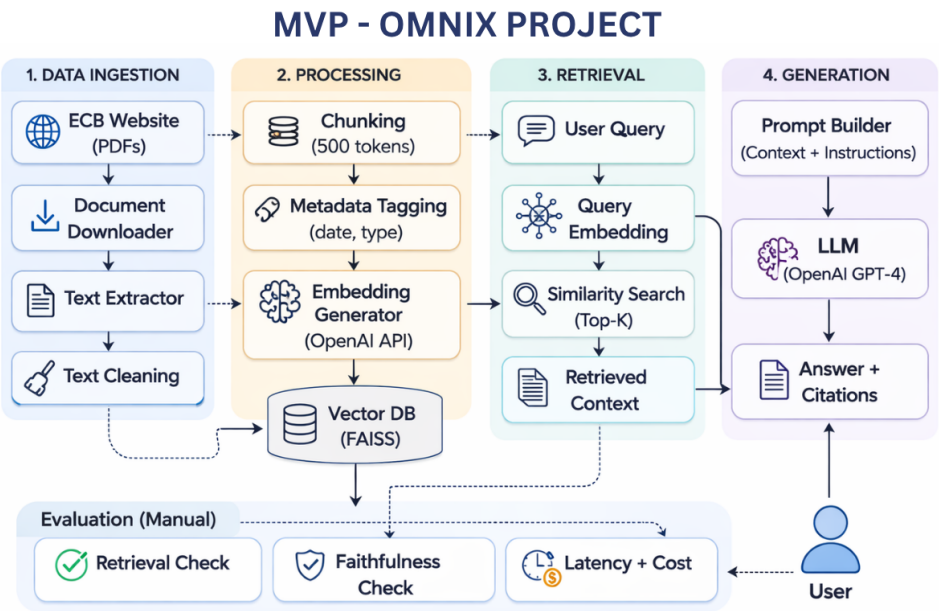

Figura 1: Diagrama de flujo. MVP - Omnix Project

2 Antecedentes y Motivación

En el contexto de la gestión de información digital, la creciente disponibilidad de documentos en múltiples formatos ha puesto en evidencia las limitaciones de los sistemas tradicionales de recuperación basados en palabras clave. Estos enfoques, si bien eficientes en términos computacionales, presentan dificultades para capturar relaciones semánticas complejas entre conceptos, especialmente cuando las consultas del usuario requieren interpretación contextual más allá de coincidencias léxicas.

Los modelos basados en embeddings y técnicas de representación semántica han permitido avanzar hacia sistemas capaces de comprender similitudes conceptuales entre textos. Al representar fragmentos de documentos en espacios vectoriales densos, es posible medir la proximidad semántica entre una consulta y distintos segmentos de información, facilitando una recuperación más relevante y precisa. En este sentido, las bases de datos vectoriales se han consolidado como un componente clave en arquitecturas modernas de recuperación de información.

Sin embargo, la recuperación por sí sola no es suficiente para proporcionar respuestas completas y coherentes. La incorporación de modelos generativos de lenguaje permite sintetizar la información recuperada y transformarla en respuestas estructuradas, dando lugar a la arquitectura Retrieval-Augmented Generation (RAG). Este enfoque combina lo mejor de ambos mundos: la precisión de los sistemas de recuperación y la flexibilidad de los modelos generativos.

La motivación de este trabajo radica en desarrollar un sistema que integre estas capacidades para transformar colecciones de documentos estáticos en un sistema interactivo de consulta semántica. De este modo, se busca mejorar la accesibilidad al conocimiento contenido en documentos extensos, reducir la dependencia de búsquedas exactas y habilitar una experiencia de usuario más natural, donde las preguntas puedan formularse en lenguaje libre y las respuestas se construyan a partir de la evidencia recuperada de los propios documentos.

3 Metodología

3.1 Ingesta y Preprocesamiento de Documentos

La etapa de recolección de datos constituye un componente fundamental del sistema, ya que determina la calidad y estructura de la información utilizada posteriormente en el proceso de recuperación. En este trabajo, los datos fueron obtenidos a partir de fuentes web relacionadas con información económica, utilizando un enfoque automatizado de extracción de contenido. Un elemento clave en este proceso fue el uso de Jina como herramienta de ingesta, que permitió transformar directamente las páginas web en formato Markdown estructurado de manera eficiente. Este enfoque facilita la estandarización de documentos heterogéneos, eliminando el ruido propio del HTML y preservando únicamente el contenido relevante.

Posteriormente, se aplicó la técnica de Adaptive Chunking para la segmentación del texto. A diferencia de los enfoques tradicionales de "one-size-fits-all", que aplican el mismo método de corte a todos los documentos, Adaptive Chunking analiza cada documento de forma individual y selecciona automáticamente el método de chunking más adecuado según cinco métricas intrínsecas de calidad: References Completeness, Intrachunk Cohesion, Document Contextual Coherence, Block Integrity y Size Compliance. Para ello, se evaluaron varios chunkers (incluyendo un splitter guiado por LLM y un splitter recursivo split-then-merge) y se eligió el que obtuvo el mejor puntaje promedio por documento, seguido de un post-procesamiento para ajustar el tamaño de los fragmentos entre 100 y 1.100 tokens. Esta estrategia permite equilibrar de manera óptima granularidad y contexto, evitando tanto la pérdida de información relevante como la dilución semántica durante la recuperación.

Adicionalmente, se aplicaron técnicas de normalización textual, tales como la eliminación de espacios redundantes, la estandarización de caracteres y la limpieza de contenido irrelevante. El objetivo de esta fase es garantizar que el texto final sea consistente, estructurado y adecuado para su posterior transformación en representaciones vectoriales y almacenamiento en la base de datos vectorial.

3.2 Generación de Embeddings

Una vez obtenidos los fragmentos de texto, el siguiente paso consiste en transformar cada uno de ellos en una representación numérica mediante modelos de embeddings. Estos modelos permiten mapear el texto a vectores densos en un espacio semántico, donde la similitud entre vectores refleja la similitud de significado entre los fragmentos.

En este trabajo, la generación de embeddings se realizó utilizando la API de OpenAI, lo que permite obtener representaciones de alta calidad y consistencia semántica para cada

chunk de texto. Cada fragmento se convierte en un vector de alta dimensionalidad que captura su contenido conceptual, facilitando así su comparación con consultas en lenguaje natural.
Este enfoque permite que las preguntas del usuario sean transformadas en el mismo espacio vectorial, posibilitando la recuperación de información basada en similitud semántica en lugar de coincidencias exactas de palabras clave. De esta forma, se mejora la capacidad del sistema para identificar fragmentos relevantes incluso cuando la redacción de la consulta difiere del contenido original.
La calidad de los embeddings es un factor determinante en el rendimiento del sistema, ya que una representación adecuada del contenido textual mejora significativamente la precisión de la recuperación. Por ello, esta etapa constituye la base fundamental para conectar de manera efectiva las consultas del usuario con los documentos indexados.

3.3 Vector Store y Recuperación de Información

Los vectores generados en la etapa anterior se almacenan conceptualmente en un espacio vectorial que permite realizar búsquedas eficientes basadas en similitud semántica. Cuando un usuario realiza una consulta, esta se transforma igualmente en un embedding utilizando el mismo modelo, obteniéndose una representación vectorial en el mismo espacio.
En este sistema RAG, no se ha implementado persistencia del índice vectorial mediante FAISS, priorizando una arquitectura simple y adecuada al carácter de prototipo funcional (MVP). Dado el tamaño reducido del conjunto de datos, la reconstrucción del índice en tiempo de ejecución no introduce una penalización significativa en rendimiento.
Formalmente, sea el conjunto de embeddings de los documentos:

$$x_i \in \mathbb{R}^d, \quad i = 1, 2, \ldots, N$$

y el embedding correspondiente a la consulta del usuario:

$$q \in \mathbb{R}^d$$

El sistema de recuperación se basa en la búsqueda de los k vecinos más similares según una función de similitud. En este caso, se emplea el producto interno sobre vectores normalizados:

$$\text{sim}(q, x_i) = q \cdot x_i$$

Dado que los vectores son normalizados:

$$\|q\| = 1, \quad \|x_i\| = 1$$

el producto interno equivale a la similitud coseno:

$$\text{sim}(q, x_i) = \cos(\theta) = \frac{q \cdot x_i}{\|q\| \, \|x_i\|}$$

El problema de recuperación se formula entonces como:

$$\arg\operatorname*{top\text{-}k}_{i} \ \text{sim}(q, x_i)$$

Dado que el número total de embeddings es reducido en este caso ($N \approx 169$), la complejidad de una búsqueda exhaustiva es:

$$O(N \cdot d)$$

lo cual resulta computacionalmente trivial en entornos modernos. En consecuencia, el coste de reconstruir el índice en cada ejecución incluyendo la carga de embeddings y su organización en memoria es despreciable.
Desde una perspectiva de ingeniería, la persistencia del índice vectorial mediante FAISS introduciría complejidad adicional sin aportar beneficios significativos en este escenario. En particular, implicaría la gestión de estructuras de índice persistente y posibles problemas de sincronización entre embeddings e índice almacenado.
Por tanto, se ha optado por reconstruir el índice en tiempo de ejecución, manteniendo un equilibrio adecuado entre simplicidad, reproducibilidad y rendimiento. Esta decisión es coherente con el alcance de un sistema MVP, y podría revisarse en escenarios con un número significativamente mayor de documentos o con requisitos estrictos de latencia y escalabilidad.

3.4 Generación de Respuestas (LLM + Prompting)

La última etapa del pipeline consiste en la generación de respuestas utilizando un modelo de lenguaje grande (LLM). En este caso, se emplea la API de OpenAI para acceder a capacidades de generación avanzadas, permitiendo producir respuestas coherentes y contextualizadas a partir de la información recuperada.
En esta fase, los fragmentos obtenidos en la etapa de recuperación junto con la consulta del usuario se combinan en un *prompt* estructurado que actúa como contexto de entrada para el modelo generativo. El modelo utiliza esta información para sintetizar una respuesta fundamentada, alineada exclusivamente con el contenido proporcionado por los documentos recuperados.
Este enfoque reduce la dependencia del conocimiento paramétrico del modelo y restringe la generación a evidencia externa, lo que contribuye a mejorar la precisión y a minimizar la aparición de alucinaciones. El diseño del *prompt* resulta un elemento crítico, ya que

determina cómo se presentan los fragmentos al modelo y qué instrucciones guían el proceso de generación.
En este sistema, el contexto se estructura de forma que el modelo priorice la información más relevante y mantenga coherencia en la respuesta final. La combinación de recuperación semántica y generación condicionada permite construir un sistema flexible, capaz de responder a consultas diversas sobre grandes volúmenes de documentos, transformando repositorios estáticos en un sistema interactivo de consulta inteligente.

3.5 API y despliegue del sistema

Para la exposición del sistema en un entorno más cercano a producción, el modelo fue desplegado mediante una API REST que actúa como capa de intermediación entre el usuario y el sistema RAG. Esta API se encarga de recibir las consultas formuladas desde la interfaz de usuario, procesarlas y enviarlas al pipeline de recuperación y generación de respuestas.
En este diseño, el frontend se utiliza únicamente como interfaz de interacción, permitiendo al usuario enviar preguntas de manera sencilla a través de un chatbot. Las consultas son transmitidas a la API, la cual gestiona la comunicación con el backend del sistema, ejecutando el proceso completo de embedding, recuperación de contexto y generación de respuesta.
Es importante destacar que, aunque el sistema ha sido probado inicialmente en un entorno local para validar su correcto funcionamiento, la implementación de la API permite desacoplar la lógica del modelo de la interfaz de usuario, facilitando su despliegue y escalabilidad. De este modo, el núcleo del sistema permanece centrado en el backend, mientras que el frontend actúa únicamente como punto de entrada de las consultas. En un escenario de producción, este enfoque permitiría desplegar el backend en servicios cloud como Render o Railway, encargados de ejecutar automáticamente la API y garantizar su disponibilidad continua, mientras que el frontend podría alojarse en plataformas como Vercel o Netlify, proporcionando una interfaz accesible mediante una URL pública; no obstante, este paso no se ha llevado a cabo en la presente fase del proyecto debido a su enfoque prioritario en el desarrollo funcional del sistema y a limitaciones de tiempo, quedando como una línea natural de extensión para su futura puesta en producción.

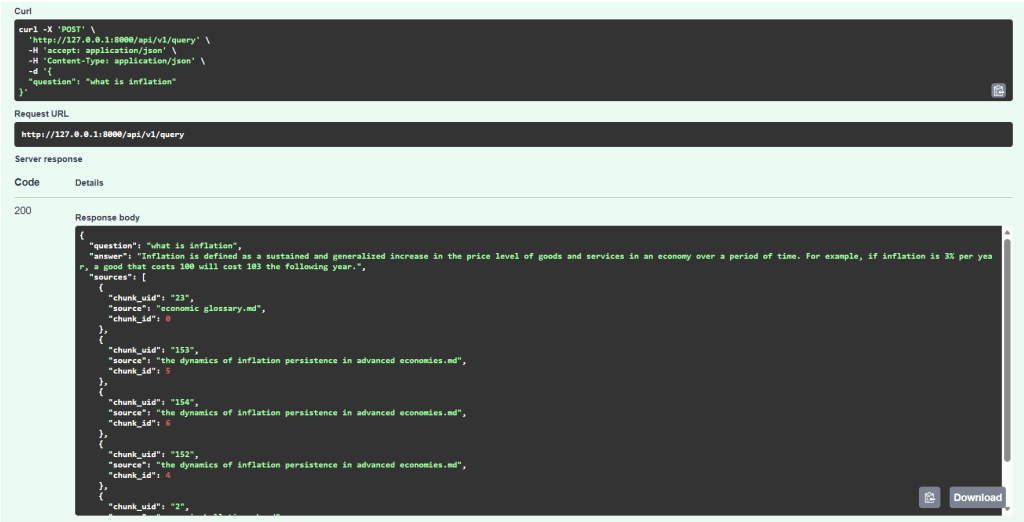

Figura 2: Arquitectura de despliegue mediante API del sistema RAG

4 Experimentos y Evaluación

En esta sección se evalúa el comportamiento del sistema RAG implementado mediante distintos casos de prueba, con el objetivo de analizar tanto su capacidad de recuperación semántica como la calidad de las respuestas generadas. Las pruebas se dividen en dos escenarios principales: consultas fuera del dominio del sistema y consultas directamente relacionadas con el dominio económico.

4.1 Caso 1: Consulta fuera de dominio

En este primer experimento se evalúa la capacidad del sistema para manejar preguntas no relacionadas con el corpus documental disponible. En particular, se plantea una pregunta de carácter geográfico:
Pregunta: what is the capital of Venezuela?
El sistema responde correctamente indicando la ausencia de información relevante en los documentos recuperados, lo cual es un comportamiento esperado dentro de un entorno RAG controlado por contexto.
Respuesta del sistema:

> I don't have enough information in the provided documents.

A continuación, se muestran los fragmentos recuperados junto con sus puntuaciones de similitud:

Rank	Score	Fragmento recuperado
1	0.1986	Definición de “vacations” y GDP per Capita
2	0.1899	Working capital y Moral Hazard
3	0.1893	Conceptos de Cash y depreciación monetaria
4	0.1873	GDP y curva de Lorenz
5	0.1751	Moral Hazard (definición conceptual)

Cuadro 1: Resultados de recuperación - Consulta fuera de dominio

Este resultado evidencia que el sistema no fuerza respuestas fuera del contexto disponible, sino que limita la generación a la información recuperada.

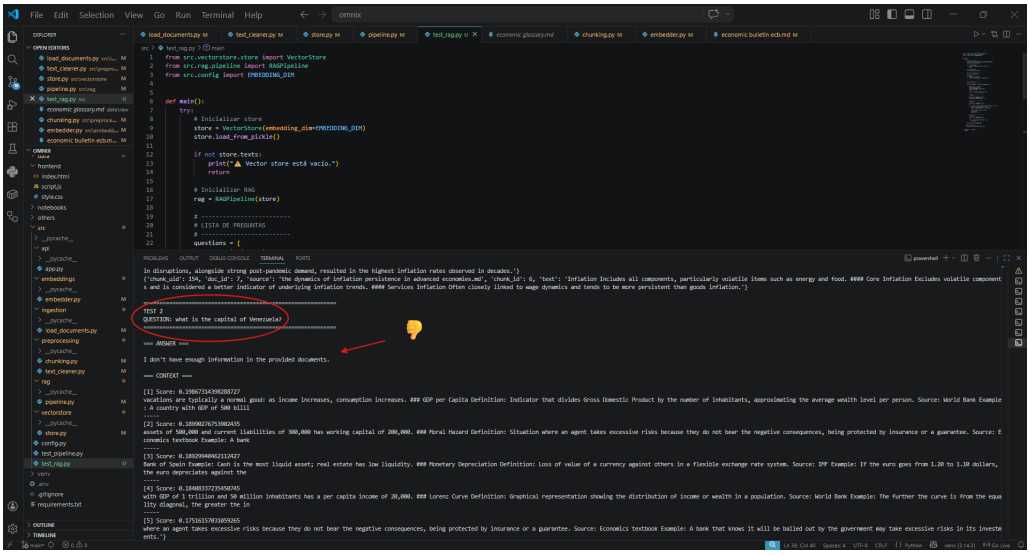

Figura 3: Salida del sistema para consulta fuera de dominio

4.2 Caso 2: Consulta dentro de dominio

En este segundo experimento se evalúa el desempeño del sistema ante una consulta directamente relacionada con el dominio económico del corpus:

Pregunta: what is inflation?

El sistema genera una respuesta correcta, coherente y alineada con los documentos recuperados, demostrando la efectividad del enfoque RAG.

Respuesta del sistema:

> Inflation is a sustained and generalized increase in the price level of goods and services in an economy over a period of time. For example, if inflation is 3 % per year, a good that costs 100 will cost 103 the following year.

Los fragmentos recuperados presentan altas puntuaciones de similitud semántica:

Rank	Score	Fragmento recuperado
1	0.5860	Definición de inflación (Banco de España / IMF)
2	0.5205	Mecanismos de inflación y rigideces de mercado
3	0.5032	Persistencia de la inflación
4	0.4993	Choques de oferta y dinámica post-pandemia
5	0.4885	Inflación núcleo vs. inflación general

Cuadro 2: Resultados de recuperación - Consulta dentro de dominio

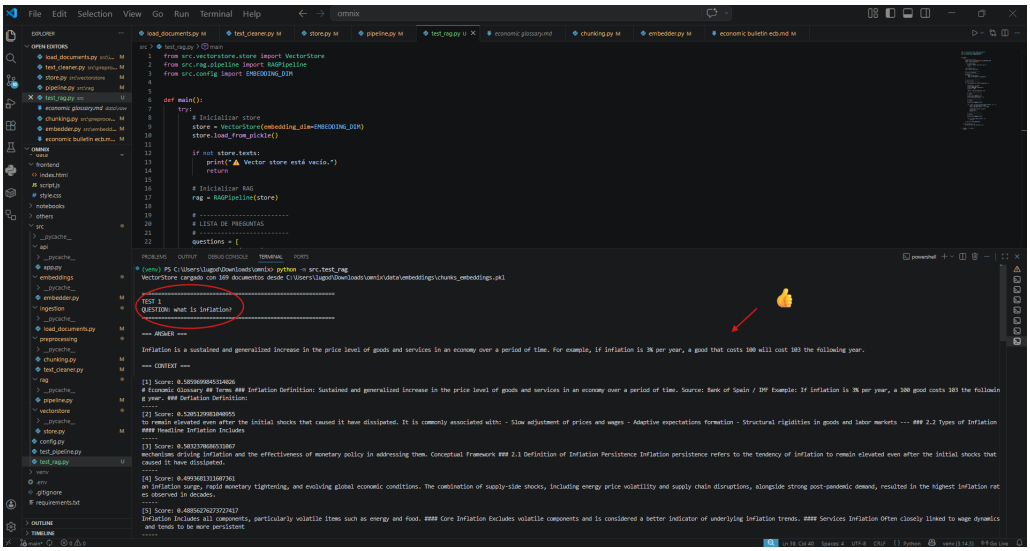

Figura 4: Salida del sistema para consulta fuera de dominio

En conjunto, los resultados muestran que el sistema es capaz de diferenciar adecuadamente entre consultas relevantes y no relevantes, manteniendo coherencia en las respuestas y utilizando únicamente la información disponible en el corpus documental.
De forma complementaria, las pruebas realizadas permiten confirmar que el rendimiento del sistema se mantiene estable bajo distintos tipos de consultas, incluyendo variaciones en la formulación de las preguntas y en la complejidad semántica de las mismas. Esto sugiere que la arquitectura implementada no solo es funcional en un entorno controlado, sino que también presenta un comportamiento robusto frente a escenarios más cercanos a un uso real, lo que refuerza la validez del enfoque adoptado en este trabajo.

5 Resultados

Los resultados obtenidos en este proyecto confirman la viabilidad de un sistema RAG como solución efectiva para la recuperación y generación de respuestas basadas en un corpus documental acotado. El sistema demuestra una capacidad consistente para localizar información relevante dentro del espacio vectorial y utilizarla como base para generar respuestas coherentes, evitando en la mayoría de los casos la introducción de contenido no soportado por los datos.

Asimismo, se observa que la calidad de las respuestas está directamente relacionada con la pertinencia de los fragmentos recuperados. Cuando el módulo de recuperación identifica correctamente los contextos más relevantes, el modelo generativo produce salidas más precisas, estructuradas y alineadas con la consulta del usuario, lo que valida la importancia crítica del componente de búsqueda semántica dentro de la arquitectura.
Otro aspecto relevante es el comportamiento del sistema ante consultas fuera de dominio. En estos casos, el modelo tiende a mantener una actitud conservadora, limitándose a la información disponible o indicando la falta de evidencia en el corpus, lo cual contribuye a reducir el riesgo de alucinaciones y mejora la confiabilidad global del sistema.
En términos generales, los resultados obtenidos permiten concluir que la solución implementada no solo es funcional a nivel técnico, sino que también cumple con criterios básicos de utilidad práctica, especialmente en escenarios donde se requiere asistencia basada en documentación interna o conocimiento especializado.

6 Guía de Uso

El sistema desarrollado se presenta como un prototipo accesible a través de una interfaz web tipo chatbot, diseñado para permitir la interacción directa mediante lenguaje natural. A continuación, se describen las pautas básicas de uso y consideraciones relevantes:

- **Inicio del sistema (entorno local):** Para ejecutar el prototipo, es necesario iniciar previamente el servidor backend mediante el comando correspondiente (por ejemplo, utilizando Uvicorn). Una vez activo, el usuario puede abrir la interfaz web (archivo HTML) en el navegador, lo que habilita la comunicación con la API y permite comenzar la interacción.

- **Forma de uso:** El usuario debe introducir sus consultas en lenguaje natural, sin necesidad de emplear comandos específicos ni conocimientos técnicos previos.

- **Idioma de las consultas:** Se recomienda realizar las preguntas en inglés, ya que el modelo ha sido optimizado principalmente con documentación en este idioma, lo que permite obtener respuestas más precisas y coherentes. La incorporación de soporte multilingüe se contempla como una mejora futura del sistema.

- **Buenas prácticas en las consultas:** Se recomienda formular preguntas claras, concretas y bien delimitadas. En caso de consultas complejas, es preferible dividirlas en varias preguntas más simples para mejorar la precisión de las respuestas.

- **Ejemplos de preguntas recomendadas:**

    - *What are the key factors driving inflation persistence in advanced economies after 2022?*

- *How do labor market dynamics affect core inflation trends?*
- *What role do inflation expectations play in monetary policy effectiveness?*

- **Alcance del sistema:** El modelo responde exclusivamente con base en el corpus documental utilizado durante su construcción. No dispone de acceso a fuentes externas ni a información en tiempo real.

- **Limitaciones del prototipo (MVP):**
  - No cuenta con memoria conversacional a largo plazo
  - La precisión puede variar según el contexto recuperado
  - Capacidad limitada para gestionar consultas fuera del dominio definido

- **Recomendaciones de uso:** El sistema está orientado a consultas informativas basadas en documentación, definiciones o búsqueda de contenido específico. No se recomienda su uso para preguntas subjetivas o que requieran conocimiento externo no presente en el corpus.

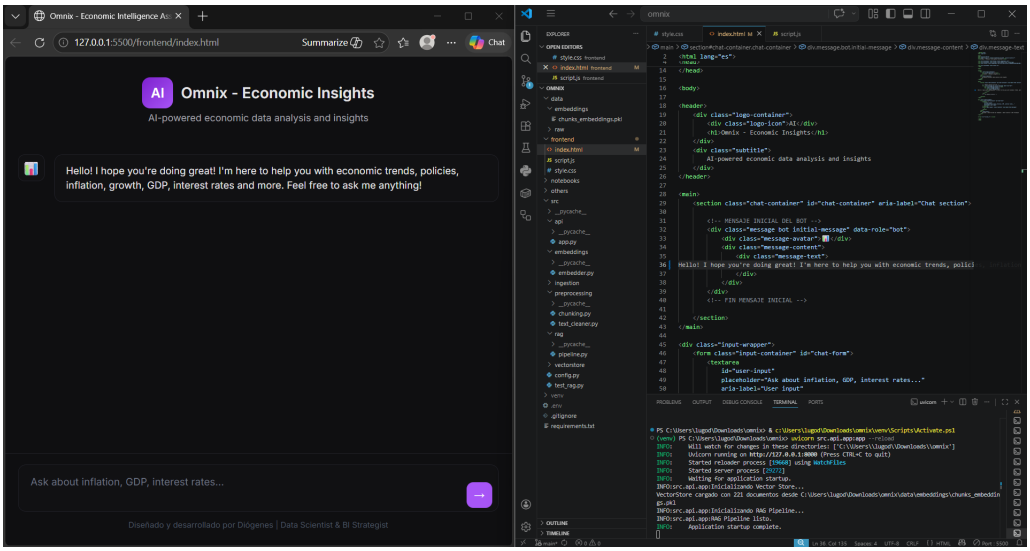

Figura 5: Interfaz web del sistema en entorno local

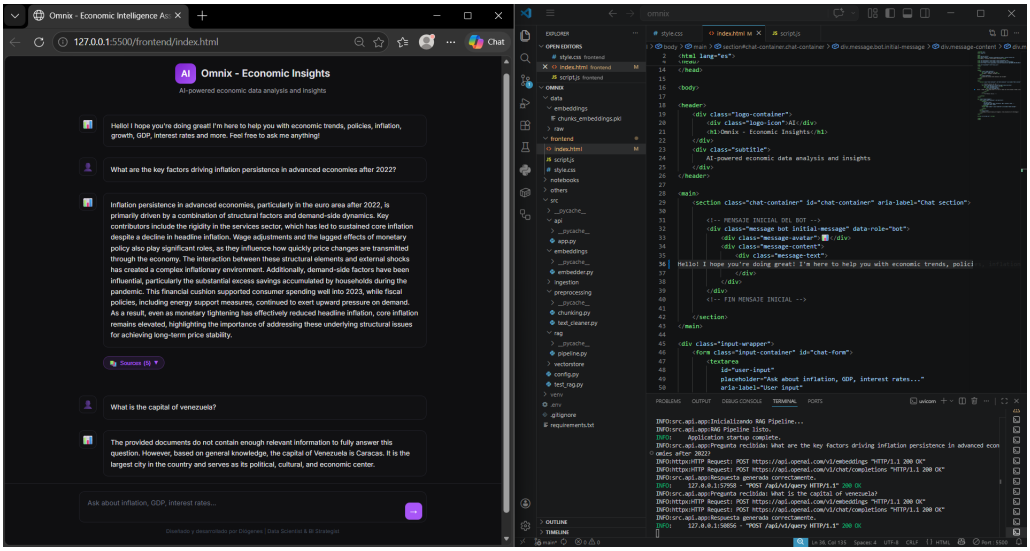

Figura 6: Chatbot en uso con dos preguntas de prueba

7 Conclusiones y Trabajo Futuro

El presente proyecto ha permitido desarrollar un sistema de tipo RAG orientado a la recuperación y generación de respuestas basadas en un corpus documental específico, integrando técnicas de embeddings, búsqueda semántica y modelos generativos. A lo largo del trabajo se ha demostrado la viabilidad de este enfoque para construir un asistente capaz de responder preguntas en lenguaje natural de forma coherente y fundamentada en datos.

Los resultados obtenidos confirman que la arquitectura implementada cumple adecuadamente con los objetivos propuestos en esta fase inicial, logrando una correcta diferenciación entre consultas dentro y fuera de dominio, así como una generación de respuestas consistente con la información recuperada. En este sentido, el sistema se comporta como una solución funcional y robusta a nivel prototípico.

Sin embargo, al tratarse de un MVP, existen limitaciones relevantes que deben ser consideradas, especialmente en términos de escalabilidad, memoria conversacional y enriquecimiento del corpus. Estas restricciones no afectan la validez del enfoque, pero sí condicionan su uso en entornos más exigentes o productivos.

Como trabajo futuro, se plantean varias líneas de mejora. En primer lugar, la incorporación de persistencia del índice vectorial y optimización del pipeline de recuperación permitiría mejorar el rendimiento general del sistema. En segundo lugar, la ampliación del corpus documental y la inclusión de mecanismos de actualización dinámica incrementarían su utilidad práctica. Finalmente, la integración de memoria conversacional y técnicas avanzadas de reranking o agentes podría elevar significativamente la calidad de las respuestas y acercar el sistema a soluciones de nivel productivo.

8 Referencias

Referencias

[1] Paulo Roberto de Moura Júnior et al. Adaptive chunking: Optimizing chunking-method selection for rag. 2026. arXiv:2603.25333.

[2] Patrick Lewis et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. 2020. arXiv:2005.11401.